



UNIVERSIDAD
NACIONAL
DE COLOMBIA

Inducción de Estilos Narrativos mediante Técnicas de Few-Shot Learning

Daniel Fabián Serrano Galvis

Universidad Nacional de Colombia
Teoría del aprendizaje de máquina
Manizales, Colombia
2025

Índice

1. Motivación del Proyecto	3
1.1. Contexto General y Problema del Mundo Real	3
1.2. Justificación de la Iniciativa	3
2. Planteamiento del Problema	4
3. Estado del Arte	5
3.1. Generación de Texto con Control Estilístico	5
3.2. Fine-Tuning Eficiente (PEFT) para LLMs	5
3.3. Comparación con el Presente Proyecto	6
4. Objetivo del Proyecto	7
5. Metodología Propuesta	7
5.1. Recolección y Preprocesamiento de Datos	7
5.2. División de Datos y Estrategia de Entrenamiento	8
5.3. Selección de Algoritmos y Arquitecturas	8
5.4. Métricas de Evaluación	9
5.5. Estrategias de Mejora del Rendimiento	9
6. Background de los Modelos Utilizados	10
6.1. Modelos de Lenguaje Grandes (LLMs)	10
6.2. Fine-Tuning Tradicional y sus Limitaciones	10
6.3. Prompt Tuning	11
6.4. Low-Rank Adaptation (LoRA)	11
6.5. Justificación de su Elección para el Proyecto	12
7. Configuración Experimental	12
7.1. Entorno de Desarrollo y Librerías	12
7.2. Especificaciones del Hardware	13
7.3. Configuración del Experimento y Proceso de Entrenamiento	13
8. Resultados y Discusión	15
8.1. Eficiencia del Entrenamiento con LoRA	15
8.2. Inducción Cualitativa de Estilos Narrativos	15
8.3. Limitaciones Observadas y Resolución	16
8.4. Comparación entre LoRA y Prompt Tuning	17
9. Conclusiones y Trabajo Futuro	17
9.1. Conclusiones Clave	17
9.2. Limitaciones del Presente Estudio	18
9.3. Trabajo Futuro	19
Referencias	20
Anexo A: Ejemplos del Dataset	21

A. Anexo A: Ejemplos de los Datasets	21
A.1. Ejemplos de Estilo Épico (Inglés)	21
A.2. Ejemplos de Estilo Ciencia Ficción (sci-fi , Inglés)	21
A.3. Ejemplos de Estilo Noir (Inglés)	21

1. Motivación del Proyecto

La capacidad de generar texto no solo coherente y gramaticalmente correcto, sino también estilísticamente distintivo, representa un desafío significativo y una oportunidad creciente en el campo del Procesamiento del Lenguaje Natural (PLN). En la era actual, donde la interacción con la inteligencia artificial se vuelve cada vez más omnipresente, surge una demanda de sistemas que no solo comprendan el lenguaje, sino que también puedan emular la riqueza y variedad de la expresión humana.

1.1. Contexto General y Problema del Mundo Real

El problema general del mundo real que se desea abordar con este proyecto se enmarca en la personalización y adaptación de la generación de texto. Esto abarca desde la creación de contenido altamente estilizado hasta la adaptación de narrativas existentes. Las aplicaciones potenciales son vastas e incluyen:

- **Asistentes de Escritura Personalizados:** La posibilidad de desarrollar asistentes inteligentes capaces de escribir o reescribir textos imitando el estilo narrativo de un autor específico, una personalidad, o incluso el estilo personal del usuario, facilitando la creación de contenido coherente y con una voz particular.
- **Adaptación Narrativa en Videojuegos y Medios Interactivos:** Ajustar dinámicamente el estilo de la narrativa en videojuegos para que se adapte al progreso del jugador, a sus decisiones, o incluso para emular un estilo literario concreto (*épico*, *noir*, *ciencia ficción*) en tiempo real, enriqueciendo la inmersión y la experiencia del usuario.
- **Creación de Contenido Acelerada:** En industrias como la editorial, el marketing o el entretenimiento, la capacidad de generar rápidamente contenido con un estilo predefinido puede optimizar los flujos de trabajo y reducir los costos de producción.
- **Personalización de Comunicaciones:** Adaptar el tono y estilo de las comunicaciones (correos electrónicos, respuestas de *chatbots*) para que resuenen mejor con la audiencia o la marca.

La relevancia de aplicar técnicas de ML/DL en este caso radica en su habilidad inherente para aprender patrones complejos del lenguaje a partir de datos, una capacidad que los enfoques basados en reglas no pueden igualar para la sutileza y diversidad estilística.

1.2. Justificación de la Iniciativa

La motivación para abordar este proyecto se sustenta en razones técnicas, sociales, económicas y científicas:

- **Justificación Técnica:** A nivel técnico, la inducción de estilo presenta un desafío considerable. No se trata solo de la generación de texto, sino de controlar atributos específicos de forma y tono, que son intrínsecamente complejos. La aplicación de LLMs con técnicas de *fine-tuning* eficiente como LoRA permite explorar cómo un modelo puede internalizar y replicar estas características estilísticas a partir de un número mínimo de ejemplos, un aspecto crucial en un dominio donde los datos etiquetados para estilos específicos son escasos. Esto contribuye a la capacidad de los modelos para operar en escenarios de *data scarcity*.

-
- **Justificación Social:** Potencialmente, este tipo de herramientas puede democratizar la creación de contenido estilizado, permitiendo a individuos sin formación literaria especializada producir textos con una calidad narrativa superior. Además, puede fomentar nuevas formas de expresión artística y creativa al habilitar la interacción con LLMs para explorar diferentes voces y narrativas.
 - **Justificación Económica:** La automatización y asistencia en la creación de contenido estilizado puede generar eficiencias significativas en costos y tiempo para industrias que dependen fuertemente de la producción textual. Esto incluye la reducción de la necesidad de escritores especializados para ciertos tipos de contenido o la aceleración de los ciclos de producción.
 - **Justificación Científica:** Desde una perspectiva científica, este proyecto contribuye a la comprensión de cómo las técnicas de *Parameter-Efficient Fine-Tuning* (PEFT) pueden manipular aspectos abstractos del lenguaje como el estilo, especialmente en contextos de *few-shot learning*. La exploración de Prompt Tuning y LoRA en esta tarea específica añade evidencia sobre sus fortalezas y limitaciones comparativas, enriqueciendo el conocimiento sobre la adaptabilidad de los LLMs y abriendo nuevas vías para futuras investigaciones en el control fino de la generación de texto. La dificultad inherente de la evaluación de estilo también subraya la necesidad de avanzar en metodologías de evaluación más allá de las métricas cuantitativas estándar.

2. Planteamiento del Problema

El campo del Procesamiento del Lenguaje Natural (PLN) ha logrado avances significativos en la generación de texto coherente y contextualmente relevante. Sin embargo, la capacidad de los Modelos de Lenguaje Grandes (LLMs, por sus siglas en inglés) para adoptar y mantener estilos narrativos específicos con una cantidad limitada de datos sigue siendo un desafío y un área activa de investigación. Tradicionalmente, la adaptación de LLMs a dominios o tareas específicas ha requerido costosos procesos de ajuste fino (fine-tuning) que demandan grandes volúmenes de datos y recursos computacionales considerables.

En este contexto, el problema general que aborda este proyecto se centra en la **exploración de la eficacia de técnicas de *few-shot learning* para la inducción de estilos narrativos específicos en modelos de lenguaje pre-entrenados, utilizando un número muy limitado de ejemplos por estilo**. Específicamente, se busca responder a la siguiente pregunta de investigación:

¿En qué medida pueden las técnicas de fine-tuning eficiente, como Prompt Tuning y Low-Rank Adaptation (LoRA), inducir de manera efectiva estilos narrativos distintivos en modelos de lenguaje pre-entrenados utilizando únicamente un número reducido de ejemplos por estilo?

Para abordar esta cuestión, se define el problema computacional como la tarea de transformar frases o fragmentos de texto con un estilo neutro a un estilo narrativo objetivo (e.g., épico, ciencia ficción, *noir*, o telenovela), basándose en un conjunto muy pequeño de ejemplos de este estilo.

El dominio de aplicación de la solución propuesta abarca dos conjuntos de datos curados manualmente, uno en español y otro en inglés, diseñados específicamente para esta tarea de inducción de estilo.

-
- **Conjunto de Datos en Español:** Incluye ejemplos de estilos narrativos *Épico* (inspirado en obras como Game of Thrones, El Señor de los Anillos y The Witcher), *Ciencia Ficción* (con ejemplos de Black Mirror, Blade Runner y Foundation) y *Telenovela* (basado en producciones como Yo soy Betty, la Fea, Pasión de Gavilanes y La Reina del Sur).
 - **Conjunto de Datos en Inglés:** Contiene ejemplos de estilos *Épico* (con las mismas fuentes que el español) y *Noir* (inspirado en películas como Chinatown, The Maltese Falcon y Double Indemnity).

Cada ejemplo en estos conjuntos de datos consiste en un par de frases: una versión original con estilo neutro y una versión reescrita que manifiesta claramente el estilo narrativo deseado, junto con la etiqueta del estilo y la fuente de inspiración. La selección y curación manual de estos datos fueron realizadas con el objetivo de asegurar la claridad y representatividad de los estilos para la tarea de *few-shot learning*.

3. Estado del Arte

El control de la generación de texto y la adaptación de estilos narrativos ha sido un área de investigación activa en el PLN, evolucionando significativamente con la aparición de los Modelos de Lenguaje Grandes (LLMs). Esta sección presenta un resumen de trabajos relacionados que contextualizan la presente investigación, destacando enfoques anteriores, sus fortalezas y limitaciones.

3.1. Generación de Texto con Control Estilístico

Tradicionalmente, la generación de texto con control de estilo ha empleado diversas estrategias, desde modelos basados en reglas o gramáticas hasta enfoques neuronales que utilizan codificadores/decodificadores o redes generativas adversarias (GANs). Sin embargo, la complejidad de capturar y reproducir matices estilísticos ha sido un obstáculo. Trabajos seminales en control estilístico a menudo requerían grandes datasets paralelos de texto en diferentes estilos o dependían de representaciones latentes disentangled. Por ejemplo, Fidler y Goldberg (2017) exploraron la generación de texto controlable para atributos de estilo específicos, pero su enfoque a menudo dependía de la disponibilidad de datasets etiquetados con dichos atributos. Otro trabajo relevante es el de Shen et al. (2017), que propuso un modelo basado en autoencoders variacionales para la transferencia de estilo en texto, separando el contenido del estilo. Si bien estos enfoques sentaron las bases, a menudo resultaban complejos de entrenar, requerían arquitecturas específicas para cada tarea o no escalaban bien a la diversidad de estilos que un LLM puede aprender.

3.2. Fine-Tuning Eficiente (PEFT) para LLMs

Con la escala de los LLMs modernos, el *fine-tuning* completo se ha vuelto prohibitivo en términos de recursos. Esto ha impulsado el desarrollo de técnicas de *Parameter-Efficient Fine-Tuning* (PEFT).

Prompt Tuning

El concepto de *Prompt Tuning* se popularizó con trabajos como Lester et al. (2021). Este estudio demostró que el *Prompt Tuning*, que solo optimiza un pequeño conjunto de *tokens* continuos (*soft prompts*) prepuestos a la entrada del modelo, puede ser sorprendentemente eficaz y, en algunos casos, comparable al *fine-tuning* completo en términos de rendimiento.

- **Fortalezas:** Requiere el entrenamiento de un número muy reducido de parámetros, lo que se traduce en una drástica reducción de la huella de memoria y del tiempo de entrenamiento. Además, permite la reutilización del modelo base congelado y el almacenamiento de adaptadores muy pequeños por tarea.
- **Limitaciones:** Como se observó en este proyecto, su eficacia puede ser variable y altamente dependiente del modelo base y de la complejidad de la tarea. En tareas de generación de texto libre o con alta sensibilidad al *prompting*, como la inducción de estilos narrativos con pocos ejemplos, puede no ser lo suficientemente robusto para guiar al LLM de manera consistente hacia el comportamiento deseado. La estabilidad y el control preciso del estilo pueden ser difíciles de lograr.

Low-Rank Adaptation (LoRA)

LoRA (*Low-Rank Adaptation of Large Language Models*), introducido por Hu et al. (2021), ha emergido como una de las técnicas PEFT más influyentes y eficaces. LoRA adapta el modelo inyectando matrices de bajo rango en las capas de atención del LLM pre-entrenado, congelando los pesos originales y entrenando solo estas pequeñas matrices de adaptación.

- **Fortalezas:** Ofrece un excelente equilibrio entre eficiencia y rendimiento. Permite alcanzar un rendimiento comparable al *fine-tuning* completo con solo una fracción minúscula de parámetros entrenables. Es compatible con casi todas las arquitecturas de *Transformers* y reduce significativamente la memoria VRAM necesaria para el entrenamiento y el tamaño de los modelos adaptados. Su éxito se debe a la observación de que las actualizaciones de los pesos durante el *fine-tuning* suelen tener un rango intrínseco bajo.
- **Limitaciones:** Aunque muy robusta, la elección de hiperparámetros como el rango (r) puede influir en el rendimiento. En tareas altamente creativas y subjetivas como la inducción de estilo, la evaluación de la calidad de la adaptación sigue siendo un desafío abierto, y el grado de control fino del estilo aún puede requerir exploración.

3.3. Comparación con el Presente Proyecto

Mientras que los trabajos existentes han establecido las bases para la generación controlada de texto y el *fine-tuning* eficiente, este proyecto se distingue por la **exploración directa de PEFT (*Prompt Tuning* y LoRA) en un escenario de *few-shot learning* para la inducción de estilos narrativos específicos y culturalmente diversos**. Muchos estudios de PEFT se centran en tareas más estructuradas (clasificación, resumen), y aunque algunos abordan la generación, pocos se han enfocado en la inducción de estilo con un número tan limitado de ejemplos, y menos aún con la consideración de estilos tan cualitativos como “telenovela” o “noir” en múltiples idiomas. La evaluación cualitativa

en este contexto resalta la dificultad de aplicar métricas automáticas y la necesidad de juicio humano para estas tareas creativas. El descarte de *Prompt Tuning* en favor de LoRA también proporciona una valiosa evidencia empírica sobre la robustez de estas técnicas en escenarios de *few-shot* para la generación estilística.

4. Objetivo del Proyecto

El objetivo general de este proyecto es explorar y evaluar la capacidad de las técnicas de *fine-tuning* eficiente, específicamente *Prompt Tuning* y *Low-Rank Adaptation* (LoRA), para adaptar modelos de lenguaje pre-entrenados con el fin de inducir estilos narrativos específicos a partir de un número muy limitado de ejemplos.

Para lograr este objetivo general, se plantean los siguientes objetivos específicos:

- **Implementar y Configurar** los enfoques de *Prompt Tuning* y LoRA en un modelo de lenguaje pre-entrenado (LLM) para la tarea de reescritura de texto con inducción de estilo.
- **Evaluar Cualitativamente** el rendimiento de los modelos adaptados en la generación de texto que refleje los estilos narrativos objetivo (*épico*, *ciencia ficción*, *telenovela* en español, y *noir* en inglés), basándose en la coherencia y la fidelidad estilística percibida por observadores humanos.
- **Comparar la Eficiencia** de *Prompt Tuning* y LoRA en términos de recursos computacionales y tiempo de entrenamiento, analizando su viabilidad para escenarios de *few-shot learning*.

Estos objetivos buscan ofrecer una comprensión práctica de las capacidades de estas técnicas en la adaptación estilística de LLMs, particularmente en entornos con recursos y datos limitados, donde la evaluación cualitativa es la principal medida de éxito debido a la complejidad de cuantificar métricas objetivas de estilo.

5. Metodología Propuesta

La metodología propuesta para este proyecto se estructuró en varias etapas clave, diseñadas para abordar el problema de la inducción de estilos narrativos mediante técnicas de *few-shot learning* y evaluar la eficacia de los enfoques de *fine-tuning* eficiente.

5.1. Recolección y Preprocesamiento de Datos

Los conjuntos de datos utilizados en este proyecto fueron generados y curados específicamente para la tarea de inducción de estilos narrativos. Dada la naturaleza del *few-shot learning*, se hizo énfasis en obtener ejemplos concisos y representativos de cada estilo.

- **Generación de Datos:** Las frases para los distintos estilos narrativos (*épico*, *ciencia ficción*, *telenovela* en español; *épico*, *ciencia ficción*, y *noir* en inglés) fueron generadas utilizando un Modelo de Lenguaje Grande (LLM) avanzado, específicamente ChatGPT 4o. Este LLM fue instruido para producir fragmentos de texto cortos que capturaran la esencia y las características distintivas de cada estilo, reescribiendo una frase de estilo neutro a la versión estilizada.

- **Curación Manual:** Una vez generadas, las frases fueron sometidas a un proceso de curación manual para seleccionar aquellas que mejor ejemplificaban el estilo deseado y que eran compactas y concisas. No se siguieron criterios específicos más allá de la percepción de una clara manifestación del estilo objetivo. Cada ejemplo consta de una frase original de estilo neutro, su versión reescrita en el estilo objetivo, el estilo asignado y la fuente de inspiración (ver Anexo A para ejemplos de los datasets).
- **Formato del Dataset de Entrenamiento:** El formato final del *prompt* utilizado para el *fine-tuning* fue crucial para la efectividad del modelo. Después de varias iteraciones y pruebas, se determinó que la estructura que mejor permitía al modelo seguir las instrucciones de reescritura de estilo fue la siguiente, inspirada en formatos de instrucción para LLMs:

```
<s>[INST]Rewrite the following text in [estilo] style: '[frase original]'/[/INST][frase reescrita]</s>
```

Esta estructura, que incluye los tokens especiales `[INST]` y `<s>`, fue fundamental para guiar el comportamiento del modelo durante el entrenamiento y la inferencia.

- **Tokenización:** La tokenización de los datos se realizó utilizando el `AutoTokenizer` de la biblioteca `Hugging Face`, cargado a partir del modelo pre-entrenado base (`mistralai/Mistral-7B-Instruct-v0.3`). Se configuró `tokenizer.pad_token = tokenizer.eos_token` para asegurar un manejo consistente de las secuencias de diferentes longitudes. Los procesos de tokenización incluyeron ajustes para la adecuada preparación del *prompt* y la remoción de columnas innecesarias para el entrenamiento.

5.2. División de Datos y Estrategia de Entrenamiento

Dada la naturaleza exploratoria del proyecto y el enfoque en el *few-shot learning*, la estrategia de división y uso de datos fue particular:

- **Ejemplos por Estilo:** Se utilizaron 15 ejemplos por cada estilo narrativo para el entrenamiento.
- **Ausencia de Conjuntos de Validación/Prueba Formales:** Contrario a las prácticas estándar de división de datos, en este proyecto no se crearon conjuntos separados de validación y prueba. La evaluación del rendimiento se realizó exclusivamente a través de la inferencia en tiempo real y la evaluación cualitativa directa del texto generado por el modelo para nuevas entradas, un enfoque común en proyectos exploratorios con recursos limitados y en tareas de generación de texto donde las métricas automáticas pueden no capturar la complejidad estilística.
- **Estrategias de Modelado:** Inicialmente, se entrenaron modelos separados para cada estilo individual. Posteriormente, se consolidó un único modelo entrenado con la totalidad de los tres estilos simultáneamente (45 ejemplos en total para el modelo multilingüe/multi-estilo, combinando los datos en español e inglés).

5.3. Selección de Algoritmos y Arquitecturas

Para la adaptación de estilos narrativos, se exploraron dos técnicas de *fine-tuning* eficiente: *Prompt Tuning* y *Low-Rank Adaptation* (LoRA).

-
- **Modelo Base:** Se utilizó el modelo `mistralai/Mistral-7B-Instruct-v0.3` como LLM pre-entrenado base. La elección de este modelo se fundamentó en su tamaño relativamente compacto (7B parámetros) en comparación con otros modelos de su capacidad, y su reconocida habilidad para seguir instrucciones de manera efectiva, lo cual es crucial para una tarea de reescritura condicionada por un *prompt*.
 - **Exploración de Técnicas de Fine-Tuning Eficiente:**
 - **Prompt Tuning:** Este enfoque fue explorado inicialmente. Sin embargo, los resultados preliminares mostraron que el modelo no lograba seguir las instrucciones de manera consistente, presentaba dificultades para terminar las predicciones y, en algunos casos, incluso alternaba entre idiomas de forma incontrolada (e.g., cambiaba a inglés al procesar entradas en español). Debido a estas limitaciones severas en su capacidad para adaptarse al estilo con la poca data disponible, *Prompt Tuning* fue descartado tempranamente en el desarrollo.
 - **Low-Rank Adaptation (LoRA):** Tras el descarte de *Prompt Tuning*, LoRA se convirtió en la técnica principal de *fine-tuning* eficiente. LoRA se eligió por su eficacia demostrada en la adaptación de LLMs con un bajo consumo de recursos computacionales y de datos, al inyectar matrices de bajo rango en las capas del modelo.

5.4. Métricas de Evaluación

La evaluación del rendimiento de los modelos se realizó de manera cualitativa, dada la naturaleza intrínsecamente subjetiva y creativa de la tarea de inducción de estilos narrativos.

- **Evaluación Cualitativa:** La “bondad” de las reescrituras de estilo fue juzgada por el autor del proyecto, con la supervisión y retroalimentación ocasional del profesor del curso. La evaluación se basó en la percepción directa de la fidelidad estilística: si el texto generado realmente evocaba las características léxicas, sintácticas y semánticas asociadas con el estilo objetivo (ej., el dramatismo de una telenovela, el lenguaje descriptivo de lo épico, o la atmósfera sombría del *noir*).
- **Justificación de la Ausencia de Métricas Cuantitativas:** No se emplearon métricas cuantitativas estándar (como BLEU, ROUGE, o BERTScore). La razón principal radica en que estas métricas están diseñadas para evaluar la similitud léxica o semántica entre textos y no son adecuadas para capturar la complejidad y la diversidad de las características estilísticas. La reescritura de estilo implica una alteración deliberada de la forma del texto, lo cual podría ser penalizado por métricas que buscan una alta superposición con un texto de referencia, limitando su utilidad en esta tarea creativa y subjetiva. Además, la naturaleza exploratoria y el alcance del proyecto de pregrado hacían que el desarrollo de métricas de estilo personalizadas estuviera fuera del alcance.

5.5. Estrategias de Mejora del Rendimiento

La estrategia principal para mejorar el rendimiento se centró en la configuración y optimización de LoRA, tras la rápida desestimación de *Prompt Tuning*.

-
- **Configuración de LoRA:** Para LoRA, se adoptó una configuración de hiperparámetros basada en recomendaciones de la literatura y prácticas comunes en el campo, sin una exploración exhaustiva de todo el espacio de parámetros. Los parámetros específicos utilizados fueron:
 - **r** (*rank dimension*): 8 (dimensión de rango para las matrices de actualización de LoRA).
 - **lora_alpha**: 16 (factor de escala para las capas LoRA, típicamente el doble del rango).
 - **lora_dropout**: 0.05 (probabilidad de *dropout* para las capas LoRA, para ayudar a prevenir el sobreajuste).
 - **target_modules**: ["q_proj", "v_proj"] (módulos a los que se aplica LoRA, comúnmente las proyecciones de consulta y valor en las capas de atención).
 - **bias**: "none" (no se actualizan los *biases* durante el entrenamiento LoRA).
 - **task_type**: "CAUSAL_LM" (tipo de tarea para la arquitectura del modelo, indicando generación de texto).

Esta configuración buscó un equilibrio entre la capacidad de adaptación y la eficiencia computacional.

6. Background de los Modelos Utilizados

El desarrollo de este proyecto se fundamenta en el uso de Modelos de Lenguaje Grandes (LLMs) pre-entrenados y técnicas avanzadas de *fine-tuning* eficiente, las cuales permiten adaptar estos modelos a tareas específicas con una cantidad reducida de datos y recursos computacionales.

6.1. Modelos de Lenguaje Grandes (LLMs)

Los LLMs son redes neuronales de gran escala, típicamente basadas en la arquitectura *Transformer*, que han sido entrenadas en vastos corpus de texto para aprender patrones complejos del lenguaje. Esta capacitación les permite realizar una amplia gama de tareas de Procesamiento del Lenguaje Natural (PLN), como generación de texto, traducción, resumen y respuesta a preguntas. Su naturaleza pre-entrenada les confiere un conocimiento lingüístico generalizado que puede ser adaptado a tareas más específicas. En este proyecto, el LLM base utilizado fue `mistralai/Mistral-7B-Instruct-v0.3`, seleccionado por su balance entre tamaño y capacidad de seguir instrucciones, lo cual es crucial para la tarea de inducción de estilos narrativos.

6.2. Fine-Tuning Tradicional y sus Limitaciones

El *fine-tuning* tradicional implica ajustar todos o una gran parte de los parámetros de un LLM pre-entrenado para una tarea *downstream*. Si bien es una técnica potente para especializar modelos, presenta varias limitaciones significativas:

- **Costo Computacional:** El ajuste de miles de millones de parámetros es intensivo en recursos computacionales (GPUs, memoria), lo que lo hace inaccesible para muchos investigadores y proyectos.

- **Requerimientos de Datos:** Típicamente, el *fine-tuning* de alto rendimiento requiere grandes conjuntos de datos específicos de la tarea, lo que puede ser difícil de obtener para nichos o escenarios de *few-shot learning*.
- **Almacenamiento:** Cada modelo *fine-tuned* resulta en un nuevo conjunto de pesos completo, lo que consume una cantidad considerable de espacio de almacenamiento.
- **Catastrophic Forgetting:** Existe el riesgo de que el modelo olvide conocimientos previamente adquiridos durante el pre-entrenamiento al adaptarse a la nueva tarea.

Estas limitaciones han impulsado la investigación en técnicas de *fine-tuning* eficiente, también conocidas como *Parameter-Efficient Fine-Tuning* (PEFT).

6.3. Prompt Tuning

Prompt Tuning es una técnica de PEFT que busca adaptar LLMs a nuevas tareas sin modificar los pesos del modelo base. En lugar de ajustar los parámetros internos, *Prompt Tuning* introduce un pequeño conjunto de "prompts blandos" (*soft prompts*) o *embeddings* que son concatenados a la entrada del modelo. Estos *soft prompts* son los únicos parámetros que se entrenan durante el proceso de adaptación.

- **Funcionamiento:** Se pre-aprenden vectores continuos (los *soft prompts*) que, al ser añadidos a la secuencia de entrada, "guía" al LLM para que genere la salida deseada para una tarea específica. El LLM pre-entrenado permanece congelado.
- **Eficiencia:** Su principal ventaja radica en la eficiencia. Solo se ajustan unos pocos miles de parámetros adicionales (los del *soft prompt*), en contraste con los miles de millones del modelo base. Esto reduce drásticamente el costo computacional y los requisitos de almacenamiento por tarea.
- **Hipótesis Teórica:** La hipótesis es que estos *soft prompts* actúan como instrucciones implícitas que reconfiguran el comportamiento del LLM para la tarea objetivo, aprovechando su vasto conocimiento paramétrico.

En este proyecto, *Prompt Tuning* fue explorado como una opción inicial debido a su prometedora eficiencia, aunque sus resultados no fueron satisfactorios para la tarea de inducción de estilo con el conjunto de datos limitado.

6.4. Low-Rank Adaptation (LoRA)

LoRA es otra técnica de PEFT que aborda las limitaciones del *fine-tuning* tradicional. A diferencia de *Prompt Tuning*, LoRA interviene directamente en la arquitectura del modelo inyectando matrices de bajo rango en las capas existentes del LLM, típicamente en las matrices de proyección de la atención (como las matrices **q.proj** y **v.proj**).

- **Funcionamiento:** Para una capa de peso pre-entrenado $W_0 \in \mathbb{R}^{d \times k}$, LoRA la reescribe como $W_0 + \Delta W$, donde $\Delta W = BA$. Aquí, $B \in \mathbb{R}^{d \times r}$ y $A \in \mathbb{R}^{r \times k}$ son matrices de bajo rango ($r \ll \min(d, k)$). Durante el *fine-tuning*, solo se entrenan los parámetros de A y B , mientras que W_0 permanece congelado. Esto simula una actualización de una matriz de rango completo con un número significativamente menor de parámetros entrenables.

- **Eficiencia:** La cantidad de parámetros entrenables se reduce drásticamente de $d \times k$ a $r(d + k)$. Esto resulta en una menor memoria VRAM requerida durante el entrenamiento, un entrenamiento más rápido y una reducción significativa en el tamaño de los modelos adaptados, ya que solo los pequeños adaptadores (LoRA weights) necesitan ser almacenados y cargados.
- **Ventaja Teórica:** LoRA se basa en la hipótesis de que las actualizaciones de los pesos de los modelos durante el *fine-tuning* a menudo tienen un “rango intrínseco bajo”, lo que significa que pueden ser aproximadas eficazmente por matrices de bajo rango. Esta característica permite una adaptación efectiva con un número mínimo de parámetros.

Dada la eficacia y eficiencia de LoRA en diversas tareas de PLN y su capacidad para simular actualizaciones de rango completo con pocos parámetros, fue la técnica principal empleada en este proyecto para la inducción de estilos narrativos.

6.5. Justificación de su Elección para el Proyecto

La selección de *Prompt Tuning* y LoRA para este proyecto de inducción de estilos narrativos en un escenario de *few-shot learning* se justifica por varios motivos:

- **Restricción de Datos:** Ambas técnicas están diseñadas para funcionar eficazmente con conjuntos de datos limitados, lo cual es fundamental dado que solo se disponía de 15 ejemplos por estilo.
- **Eficiencia Computacional:** Como proyecto académico de pregrado, los recursos computacionales son a menudo una limitación. Estas técnicas permiten entrenar LLMs de gran tamaño como Mistral-7B en hardware más accesible, en comparación con el *fine-tuning* completo.
- **Exploración de Estrategias PEFT:** El proyecto buscaba específicamente explorar la aplicabilidad de las PEFT en una tarea creativa como la inducción de estilo, proporcionando una visión práctica de sus capacidades y limitaciones en un contexto de investigación académica. La comparación inicial (aunque breve) entre *Prompt Tuning* y LoRA también ofreció una perspectiva sobre la robustez de cada enfoque para esta tarea particular.

7. Configuración Experimental

La fase experimental de este proyecto se llevó a cabo en un entorno de desarrollo optimizado para el entrenamiento de Modelos de Lenguaje Grandes (LLMs) y el *fine-tuning* eficiente, utilizando recursos computacionales accesibles a través de plataformas en la nube.

7.1. Entorno de Desarrollo y Librerías

El entorno de desarrollo se configuró dentro de un cuaderno de Google Colab Pro, aprovechando las capacidades de su infraestructura basada en la nube. Las principales librerías de Python utilizadas incluyen:

-
- `transformers` (para la carga y gestión de modelos y tokenizadores de Hugging Face).
 - `datasets` (para la manipulación y carga de los conjuntos de datos).
 - `peft` (para la implementación de *Low-Rank Adaptation*, LoRA).
 - `trl` (Transformers Reinforcement Learning, para funcionalidades adicionales de entrenamiento, aunque su uso principal fue la integración de PEFT con `Trainer`).
 - `accelerate` (para la gestión eficiente del uso de recursos de hardware).
 - `bitsandbytes` (para la cuantificación de modelos, permitiendo cargar el LLM en 8-bit).
 - `torch` (el *framework* de *deep learning* subyacente).
 - `pandas` (para la manipulación y visualización de datos).

La versión de Python utilizada fue compatible con las versiones más recientes de estas librerías en el entorno de Google Colab. Se configuró la variable de entorno `PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True,max_split_size_mb:128` para optimizar la asignación de memoria CUDA.

7.2. Especificaciones del Hardware

El entrenamiento y la inferencia se ejecutaron en una máquina virtual proporcionada por Google Colab Pro, con las siguientes especificaciones de hardware:

- **GPU: NVIDIA L4.** Esta GPU está diseñada para cargas de trabajo de IA y *machine learning*, ofreciendo un buen equilibrio entre rendimiento y eficiencia energética.
- **VRAM (Memoria de Video):** Aproximadamente 22.5 GB. Esta cantidad fue suficiente para cargar el modelo `Mistral-7B` en 8-bit de forma cuantificada.
- **RAM del Sistema:** Aproximadamente 53 GB.

El uso de una GPU con memoria limitada, en relación con el tamaño del modelo `Mistral-7B`, fue un factor clave que justificó la elección de LoRA y la cuantificación del modelo en 8-bit (`load_in_8bit=True`) para reducir el consumo de memoria VRAM.

7.3. Configuración del Experimento y Proceso de Entrenamiento

El *pipeline* experimental incluyó los siguientes pasos y configuraciones:

- **Modelo Base:** Se utilizó `mistralai/Mistral-7B-Instruct-v0.3` como modelo de lenguaje preentrenado. Se cargó utilizando `BitsAndBytesConfig` con `load_in_8bit=True` y `llm_int8_threshold=6.0`, lo que permitió la cuantificación del modelo para reducir su huella de memoria. El cálculo interno se realizó en `torch.float16`.
- **Tokenizador:** Se empleó `AutoTokenizer.from_pretrained` y se configuró `tokenizer.pad_token = tokenizer.eos_token`.

-
- **Dataset:** El conjunto de datos `dserranog/fewshot-narrative-examples` fue cargado directamente desde Hugging Face Hub. Para el entrenamiento del modelo multiestilo se utilizaron un total de 45 ejemplos (15 ejemplos por cada uno de los tres estilos: *épico*, *ciencia ficción* y *noir/telenovela*).

- **Formato del Prompt:** Los ejemplos del dataset se transformaron al siguiente formato específico de *prompt* para el entrenamiento:

```
<s>[INST]Rewrite the following text in [style] style: '[
    original_text]'[/INST][rewritten_text]</s>
```

Esta estructura fue crucial para guiar el comportamiento del modelo durante el entrenamiento.

- **Parámetros de LoRA:**

- `r`: 8
- `lora_alpha`: 16
- `lora_dropout`: 0.05
- `target_modules`: ["q_proj", "v_proj"]
- `bias`: "none"
- `task_type`: "CAUSAL_LM"

- **Parámetros de Entrenamiento:**

- **Épocas** (`num_train_epochs`): 3
- **Tamaño del Batch por Dispositivo** (`per_device_train_batch_size`): 1
- **Acumulación de Gradientes** (`gradient_accumulation_steps`): 4, resultando en un tamaño de *batch* efectivo de 4
- **Optimizador:** Se utilizó el optimizador AdamW, por defecto en Trainer de Hugging Face
- **Tasa de Aprendizaje** (`learning_rate`): Valor por defecto del Trainer, 5e-5
- **Registro de Pasos** (`logging_steps`): 10
- **Estrategia de Guardado** (`save_strategy`): "no"

- **Tiempo de Entrenamiento:**

- **Modelo Multiestilo (45 ejemplos):** Aproximadamente 87.23 segundos para 3 épocas
- **Modelo de Estilo Único (15 ejemplos):** Aproximadamente 29.91 segundos para 3 épocas

- **Inferencia:** La generación de texto se realizó utilizando `transformers.pipeline`, con un `batch_size` de 4 para procesar múltiples *prompts* simultáneamente. Se configuraron parámetros de muestreo como `temperature` y `top_p` para controlar la diversidad de la generación.

Esta configuración permitió una exploración eficiente de la adaptación de estilo con LoRA en un escenario de *few-shot learning*, optimizando el uso de los recursos computacionales disponibles.

8. Resultados y Discusión

Esta sección presenta los hallazgos clave derivados de la experimentación con el *fine-tuning* eficiente utilizando LoRA en el modelo **Mistral-7B-Instruct-v0.3** para la inducción de estilos narrativos. La evaluación se centró principalmente en la calidad cualitativa de la generación de texto y en la eficiencia de las técnicas exploradas.

8.1. Eficiencia del Entrenamiento con LoRA

En términos de eficiencia, LoRA demostró ser una técnica sumamente eficaz para adaptar un LLM de 7 billones de parámetros en un entorno con recursos limitados (GPU NVIDIA L4 con 22.5 GB de VRAM). Los resultados cuantitativos en cuanto a parámetros entrenables son los siguientes:

- Parámetros entrenables: 3,407,872
- Parámetros totales del modelo: 7,251,431,424
- Porcentaje de parámetros entrenables: 0.0470 %

Esta mínima fracción de parámetros entrenables valida la eficiencia de LoRA. El tiempo de entrenamiento fue igualmente notable: el modelo multi-estilo (45 ejemplos) se entrenó en aproximadamente 87 segundos, mientras que una versión con un solo estilo (15 ejemplos) tomó cerca de 30 segundos, ambos en 3 épocas. Las pérdidas de entrenamiento (*training loss*) observadas (aproximadamente 4.23 para el modelo multi-estilo y 4.92 para el modelo de estilo único) indicaron que el entrenamiento procedió sin divergencias o “explosiones” de gradientes, sugiriendo una mejora estable en la adaptación del modelo a la tarea.

8.2. Inducción Cualitativa de Estilos Narrativos

El principal criterio de éxito fue la capacidad del modelo para capturar y replicar cualitativamente los estilos narrativos definidos. El modelo LoRA entrenado con los 45 ejemplos de los estilos **épico**, **sci-fi** (ciencia ficción) y **noir** (*film noir*) demostró una notable habilidad para inducir las características distintivas de cada uno.

Para ilustrar el rendimiento, se utilizó la frase base “The phone rang at midnight.” (“El teléfono sonó a medianoche.”) y se generaron múltiples ejemplos para cada estilo. A continuación, se presentan algunas de las generaciones obtenidas:

- **Estilo Ciencia Ficción (sci-fi):**
 - “The commlink buzzed at midnight, a signal that could only mean trouble.”
 - “My communicator buzzed at midnight, a signal that could only mean trouble.”

El modelo capturó eficazmente el vocabulario (**commlink**, **communicator**) y la atmósfera de la ciencia ficción, sugiriendo tecnología futurista y un tono de inminente problema o alerta. La cohesión temática es evidente a pesar de la brevedad de las oraciones.

- **Estilo Épico:**
 - “Midnight’s silence was shattered by the phone’s insistent call, a discordant note in the symphony of the night.”

-
- “Midnight’s silence was shattered by the shrill cry of the phone, a discordant note in the symphony of the night.”

Las generaciones en estilo épico exhiben un lenguaje más grandilocuente y metafórico (*shattered, symphony of the night, discordant note, shrill cry*). Se observa una tendencia a personificar el objeto (*phone’s insistent call*) y a elevar el evento a una escala más dramática, reflejando el tono característico del género épico.

■ **Estilo Noir:**

- “The phone sang its mournful dirge at midnight.”
- “The phone jangled like a dead man’s last cry at the stroke of midnight.”
- “The phone screeched at midnight, a mournful serenade in the dead of night.”

El estilo *noir* fue particularmente bien capturado, con un uso prominente de metáforas sombrías, vocabulario evocador de fatalidad y desesperación (*mournful dirge, dead man’s last cry, screeched, mournful serenade*) y la creación de una atmósfera lúgubre y misteriosa. La personificación del teléfono adquiere un tinte oscuro y presagio.

En general, la evaluación cualitativa reveló que el modelo entrenado con LoRA fue capaz de:

- **Capturar Vocabulario Específico:** Utilizar palabras y frases asociadas a cada estilo.
- **Adaptar la Sintaxis y Estructura:** Modificar la construcción de las oraciones para ajustarse a los patrones estilísticos (ej., el dramatismo de lo épico, la concisión y metáfora del *noir*).
- **Inducir Atmósfera y Tono:** Generar texto que evocaba la sensación y el ambiente esperados de cada género.

8.3. Limitaciones Observadas y Resolución

Aunque los resultados fueron satisfactorios, se identificaron limitaciones iniciales en el comportamiento del modelo, principalmente relacionadas con el control de la longitud de la generación y la adherencia precisa a las instrucciones.

- **Dificultad en el Control de Generación y Longitud:** En las primeras iteraciones, el modelo tendía a extenderse significativamente más allá de una “oración concisa”, generando párrafos enteros que, aunque estilizados, no cumplían con el formato deseado. Por ejemplo, una generación inicial para estilo *sci-fi* podría extenderse a:

The comm-link buzzed at the dead of night, its eerie glow casting long shadows across the cold, metal floor. The silence was shattered, the only sound in the darkened room being the soft, rhythmic hum of the life-support systems. The astronaut, half-asleep, reached for the device, his

gloved hand trembling slightly as he answered the call. "This is Captain Stanton, speaking." A voice, cold and mechanical, responded from the other end. "Captain, we have detected an anomaly. Your immediate presence is required at Sector 37." The astronaut's heart skipped a beat. "Understood," he replied, his voice steady despite the sudden surge of adrenaline.

Esta tendencia fue más pronunciada en estilos que naturalmente implican descripciones más extensas, como la ciencia ficción o el épico.

- **Solución Mediante Modificación del Prompt:** Esta limitación se superó eficazmente añadiendo una instrucción explícita de concisión al *prompt* de inferencia: `*one concise sentence*`. La inclusión de esta frase dentro del *INST tag* resultó fundamental para guiar al modelo a generar respuestas breves y directas, demostrando la alta sensibilidad de los LLMs y de las adaptaciones LoRA a la formulación del *prompt*.
- **Adherencia a las Instrucciones Iniciales:** Al principio del proyecto, antes de adoptar la estructura de *prompt* con `[INST]` y `<s>` y de descartar *Prompt Tuning*, el modelo presentaba serias dificultades para seguir cualquier instrucción de forma consistente, llegando incluso a mezclar idiomas o a generar texto incoherente. Esta fase inicial subrayó la importancia crítica de la formulación del *prompt* y la elección adecuada de la técnica de *fine-tuning* eficiente.

8.4. Comparación entre LoRA y Prompt Tuning

La experiencia del proyecto validó la superioridad de LoRA sobre *Prompt Tuning* para esta tarea específica y con la configuración de datos utilizada. Mientras que *Prompt Tuning* no logró producir resultados coherentes ni seguir instrucciones básicas, LoRA demostró una capacidad robusta para adaptar el modelo base de manera efectiva. Esto se atribuye a que LoRA modifica directamente las representaciones internas del modelo a través de la inyección de matrices de bajo rango en las capas de atención, lo que le confiere un control más granular y una mayor estabilidad en la adaptación de características estilísticas complejas. Por el contrario, la dependencia de *Prompt Tuning* en la manipulación de *soft prompts* externos puede ser menos efectiva para tareas de generación creativa que requieren una modificación más profunda del comportamiento del modelo.

En resumen, los resultados cualitativos son prometedores y sugieren que LoRA es una técnica viable y eficiente para la inducción de estilos narrativos con un número muy limitado de ejemplos, aunque la formulación del *prompt* de inferencia sigue siendo un factor crítico para el control de la generación.

9. Conclusiones y Trabajo Futuro

9.1. Conclusiones Clave

Este proyecto exploró la viabilidad y eficacia de técnicas de *Parameter-Efficient Fine-Tuning* (PEFT), específicamente *Prompt Tuning* y *Low-Rank Adaptation* (LoRA), para inducir estilos narrativos específicos en un Modelo de Lenguaje Grande (LLM) pre-entrenado,

Mistral-7B-Instruct-v0.3, utilizando un número muy limitado de ejemplos. Los hallazgos clave de esta investigación son los siguientes:

- **Eficacia de LoRA para la Inducción de Estilos en Escenarios Few-Shot:** LoRA demostró ser una técnica excepcionalmente efectiva para adaptar el LLM base a la tarea de reescritura de texto con inducción de estilo. Con solo 15 ejemplos por estilo, el modelo fue capaz de generar texto que cualitativamente capturaba la esencia de los estilos *épico*, *sci-fi* y *noir*, adaptando el vocabulario, la sintaxis y la atmósfera de manera convincente. Esto confirma la promesa de LoRA para tareas creativas y subjetivas en entornos con datos escasos.
- **Superioridad de LoRA sobre Prompt Tuning:** La experimentación temprana reveló que *Prompt Tuning* no fue una técnica viable para esta tarea en particular, fallando en seguir instrucciones y producir resultados consistentes. Esto sugiere que para la inducción de estilos complejos y la generación controlada de texto, la modificación más profunda de las representaciones internas del modelo que ofrece LoRA es fundamental, en contraste con la alteración superficial de la entrada que propone *Prompt Tuning*.
- **La Formulación del Prompt es Crítica:** Un aprendizaje fundamental fue la alta sensibilidad del LLM y de la adaptación LoRA a la formulación precisa del *prompt* de inferencia. La inclusión de instrucciones específicas como **one concise sentence** fue indispensable para controlar la longitud y el formato de la salida, transformando generaciones incoherentes o excesivamente largas en respuestas precisas y estilizadas. Esto subraya la importancia de la ingeniería de *prompts* incluso después del *fine-tuning*.
- **Eficiencia Computacional y Accesibilidad:** El proyecto demostró que es posible realizar *fine-tuning* efectivo de LLMs de 7 billones de parámetros para tareas no triviales en hardware accesible (GPU con 22.5 GB de VRAM), gracias a la eficiencia de LoRA y la cuantificación del modelo. Esto reduce significativamente la barrera de entrada para la experimentación con LLMs en contextos académicos y de investigación limitada.
- **Necesidad de Evaluación Cualitativa:** La naturaleza subjetiva y creativa de la inducción de estilo refuerza la conclusión de que las métricas cuantitativas estándar de PLN no son suficientes para evaluar la calidad de las generaciones. La evaluación cualitativa por observadores humanos es indispensable para juzgar la fidelidad estilística y los matices artísticos.

En síntesis, este estudio valida a LoRA como una herramienta robusta y eficiente para la adaptación estilística de LLMs en escenarios de *few-shot learning*, abriendo puertas a nuevas aplicaciones en la creación de contenido personalizado y automatizado.

9.2. Limitaciones del Presente Estudio

A pesar de los resultados prometedores, el presente estudio posee ciertas limitaciones inherentes a su alcance y recursos disponibles:

- **Tamaño y Diversidad del Dataset:** El uso de solo 15 ejemplos por estilo, aunque intencional para demostrar el *few-shot learning*, limita la diversidad y la complejidad estilística que el modelo pudo internalizar.

-
- **Evaluación Subjetiva Única:** La evaluación cualitativa fue realizada principalmente por el autor, con el apoyo de un supervisor. Un estudio más riguroso se beneficiaría de la evaluación por parte de múltiples jueces humanos independientes, utilizando rúbricas de evaluación de estilo más detalladas para reducir el sesgo.
 - **Exploración Limitada de Hiperparámetros:** No se realizó una exploración exhaustiva del espacio de hiperparámetros de LoRA (ej., diferentes valores de `r` o `lora_alpha`), ni de las opciones de entrenamiento (ej., tasa de aprendizaje, programadores de aprendizaje).
 - **Ausencia de Métricas de Evaluación de Estilo Específicas:** Aunque se justificó la no aplicación de métricas estándar, el desarrollo o la adaptación de métricas cuantitativas que puedan capturar mejor la calidad estilística (ej., métricas basadas en incrustaciones de estilo o análisis de propiedades lingüísticas) podría complementar la evaluación cualitativa.

9.3. Trabajo Futuro

Las conclusiones de este proyecto abren diversas y emocionantes vías para futuras investigaciones y desarrollo:

- **Ampliación de Estilos y Idiomas:** Investigar la capacidad de LoRA para inducir un mayor número de estilos, incluyendo aquellos con características más sutiles o abstractas, y en un rango más amplio de idiomas, incluyendo dialectos o registros informales.
- **Generación de Textos Extensos con Consistencia Estilística:** Explorar métodos para mantener la consistencia estilística a lo largo de narrativas más largas (párrafos, secciones o incluso capítulos), lo cual es un desafío significativo en la generación de texto.
- **Control Granular del Estilo:** Desarrollar mecanismos que permitan un control más granular sobre los atributos de estilo (ej., nivel de formalidad, complejidad sintáctica, densidad de metáforas) en lugar de solo seleccionar un estilo predefinido.
- **Evaluación Híbrida:** Combinar la evaluación cualitativa con el desarrollo de métricas cuantitativas de estilo más sofisticadas que puedan correlacionarse mejor con el juicio humano, facilitando la evaluación automatizada y la comparación de modelos.
- **Personalización de Estilo Basada en Ejemplos del Usuario:** Desarrollar sistemas donde los usuarios puedan proporcionar sus propios ejemplos de estilo, permitiendo al modelo aprender y emular una “voz” verdaderamente personalizada, lo que tiene grandes implicaciones para asistentes de escritura y creación de contenido.
- **Integración con Otros Paradigmas de PEFT:** Explorar la combinación de LoRA con otras técnicas PEFT (como *adapters* o enfoques basados en más avanzados) para ver si se pueden lograr sinergias que mejoren aún más el rendimiento o la eficiencia.

Este proyecto sienta las bases para futuras investigaciones sobre la capacidad de los LLMs y las PEFT para desbloquear nuevas fronteras en la creatividad y personalización del lenguaje.

Referencias

- Ficler, J., & Goldberg, Y. (2017). Controllable Text Generation. *arXiv preprint arXiv:1712.00032*.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, L., & Chen, W. (2021). LoRA: Low-Rank Adaptation of Large Language Models. *arXiv preprint arXiv:2106.09685*.
- Lester, B., Al-Rfou, R., & Constant, N. (2021). The Power of Scale for Parameter-Efficient Prompt Tuning. *arXiv preprint arXiv:2104.08691*.
- Shen, Z., Xu, W., Long, C., & Li, X. (2017). Style Transfer from Non-Parallel Text by Cross-Alignment Using Optimal Transport. *arXiv preprint arXiv:1709.06202*.

Anexo A: Ejemplos del Dataset

A. Anexo A: Ejemplos de los Datasets

Esta sección presenta una muestra de los ejemplos que componen los datasets utilizados para el *fine-tuning* del modelo. Cada ejemplo consta de una frase original en estilo neutro y su correspondiente reescritura en el estilo narrativo objetivo, además de indicar el estilo y la fuente de inspiración (si aplica). El dataset completo se encuentra disponible en Hugging Face Hub bajo el nombre `dserranog/fewshot-narrative-examples`.

A.1. Ejemplos de Estilo Épico (Inglés)

- **Original:** “Winter was coming soon.”
- **Reescrito:** “Winter was not merely a season; it was a dark promise looming over the kingdoms.”
- **Fuente:** *Game of Thrones*
- **Original:** “The moonlight shone on the hills.”
- **Reescrito:** “The moonlight spilled over the hills where the steps of old kings still whispered on stone.”
- **Fuente:** *The Lord of the Rings*

A.2. Ejemplos de Estilo Ciencia Ficción (sci-fi, Inglés)

- **Original:** “Mia’s rating fell after her comment online.”
- **Reescrito:** “Mia’s social credit score plummeted after her last comment on the network.”
- **Fuente:** *Black Mirror*
- **Original:** “The androids didn’t dream.”
- **Reescrito:** “The replicants didn’t dream of electric sheep; they dreamt of freedom.”
- **Fuente:** *Blade Runner*

A.3. Ejemplos de Estilo Noir (Inglés)

- **Original:** “The city was very hot in the afternoon.”
- **Reescrito:** “It was a dry afternoon, and the sun lashed the city like a slap in the face.”
- **Fuente:** *Chinatown*
- **Original:** “She looked at me with deep and troubled eyes.”

-
- **Reescrito:** “Her eyes were a stormy sea, hiding shipwrecks beneath the surface.”
 - **Fuente:** *Chinatown*